

Liora
YOUR FUTURE, **DECODED.**

Rakuten Challenge

Classification Multimodale de Produits

Rakuten

PRÉSENTÉ À
Jury de soutenance — Liora

ÉQUIPE PROJET
Veyssière · Henry · Tingfen · Ouhsine

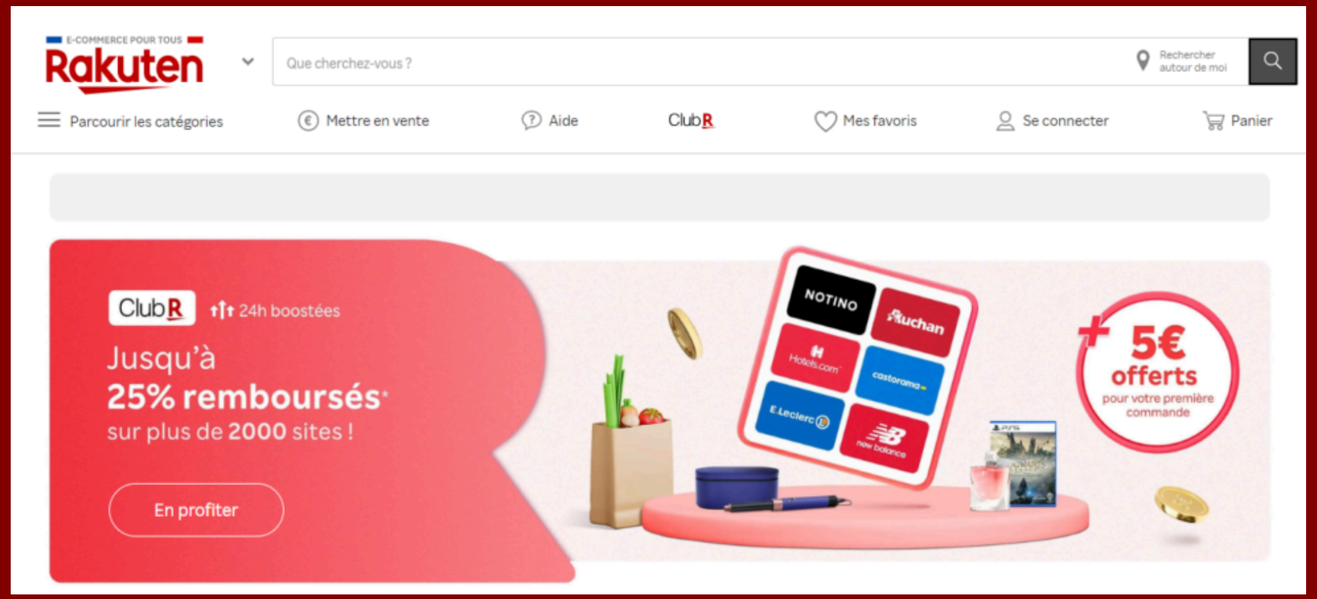


Plan de la présentation

1. **Le contexte du projet**
2. **L’exploration des données**
3. **Le pipeline de préprocessing**
4. **Strategie de modélisation**
5. **Les résultats par branche**
6. **Le stacking multimodal (OOF + MetaMLP)**
7. **Interprétabilité**
8. **Démonstration Streamilt**
9. **Bilan & Perspectives**

Contexte

Rakuten's Marketplace Automatic Classification Challenge

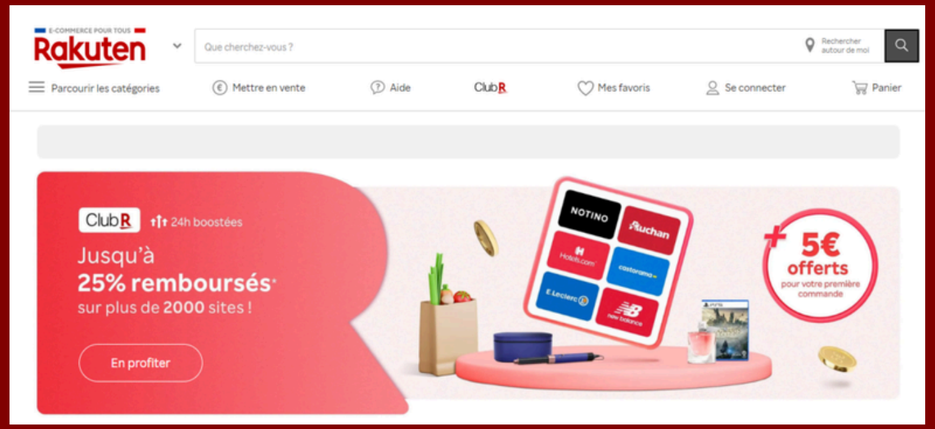


ChAllenge Data By MathA

Fondé en 1997 au Japon, à l'origine du concept de marketplace, Rakuten est aujourd'hui l'une des plus grandes plateformes e-commerce mondiales avec plus de 1,3 milliard de membres. Son département de recherch (RIT) publié ce challenge et en est le fournisseur officiel des données.

Contexte

Rakuten's Marketplace Automatic Classification Challenge



Contexte Métier :

des millions de produits soumis par des vendeurs hétérogènes, rédigés dans plusieurs langues, accompagnés d'images de qualité variable.

Chaque produit doit être associé à la bonne catégorie pour apparaître dans les bons résultats de recherche

ML réprésente un enjeu économique direct et mesurable.

Contexte Technique : Challenge Rakuten Institute of Technology × ENS Data Challenge.

Problème de classification multimodale supervisée à grande échelle

Prédire le Type de produit (27 catégories) à partir de la désignation + description + image.

Réalisé le meilleur Weighted F1-score avec 84 916 produits

Objectif

Rakuten's Marketplace Automatic Classification Challenge

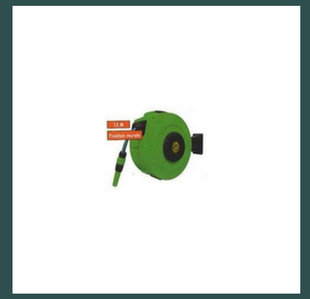
> “Construire un système multimodal capable de classifier les 27 catégories Rakuten en combinant de façon optimale texte et image pour exploiter leur complémentarité.”

Vue d'ensemble

Détails sur le Dataset de Rakuten

Le dataset comprend **84 916 produits d'entraînement** et **13 812 produits de test**, répartis en **27 catégories** issues du catalogue réel de Rakuten France. Les modalités incluent

- la désignation (exple : Folkmanis Puppets – 2732 – Marionnette Et Théâtre – Mini Turtle)
- une description optionnelle
- et une image JPEG de **500x500 pixels**.



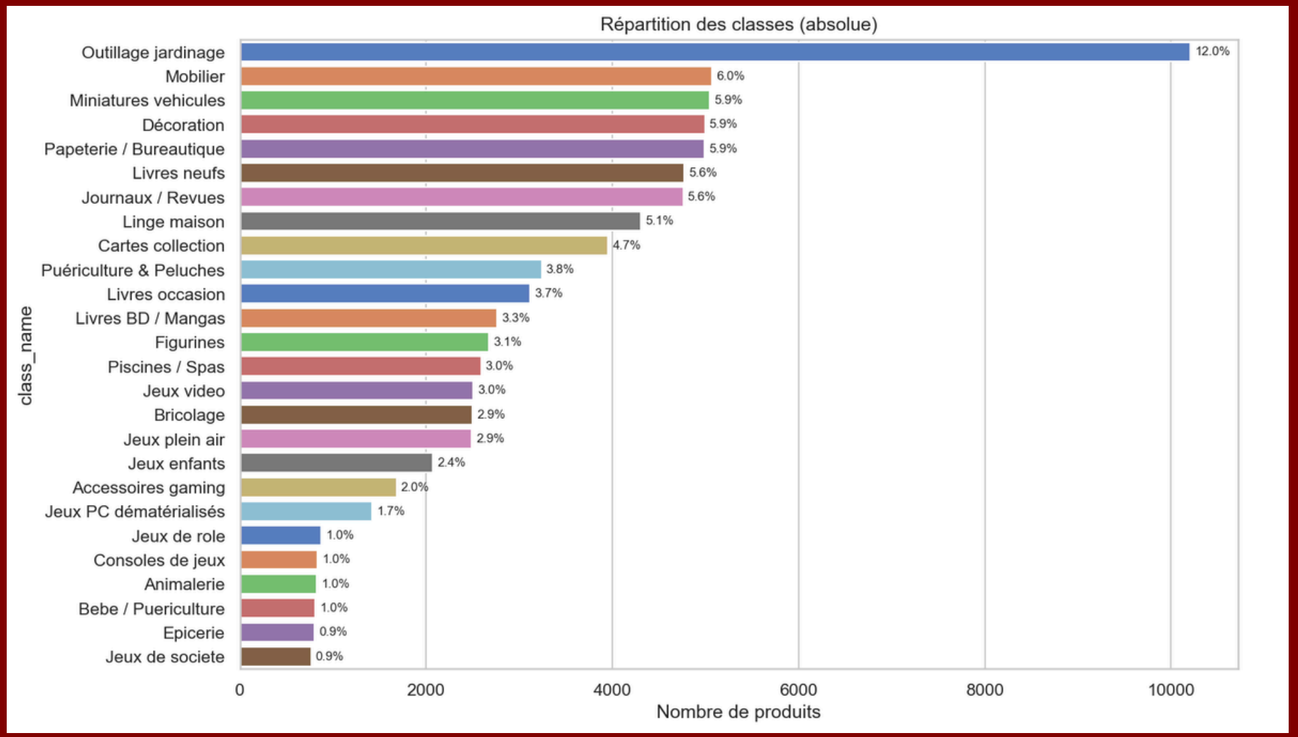




Exemple données :

```
id,designation,description,productid,imageid
84916,Folkmanis Puppets – 2732 – Marionnette Et Théâtre – Mini Turtle,,516376098,1019294171
84917,Porte Flamme Gaxix – Flamebringer Gaxix – 136/220 – U – Twilight Of The Dragons,,133389013,1274228667
84918,Pompe de filtration Speck Badu 95,,4128438366,1295960357
```

Déséquilibre des Classes



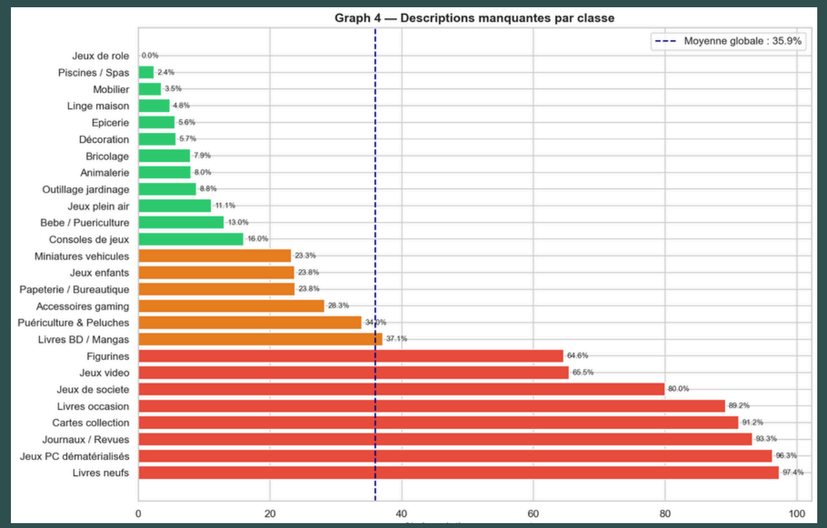
Analyse statistique des classes et leurs répartitions dans le dataset

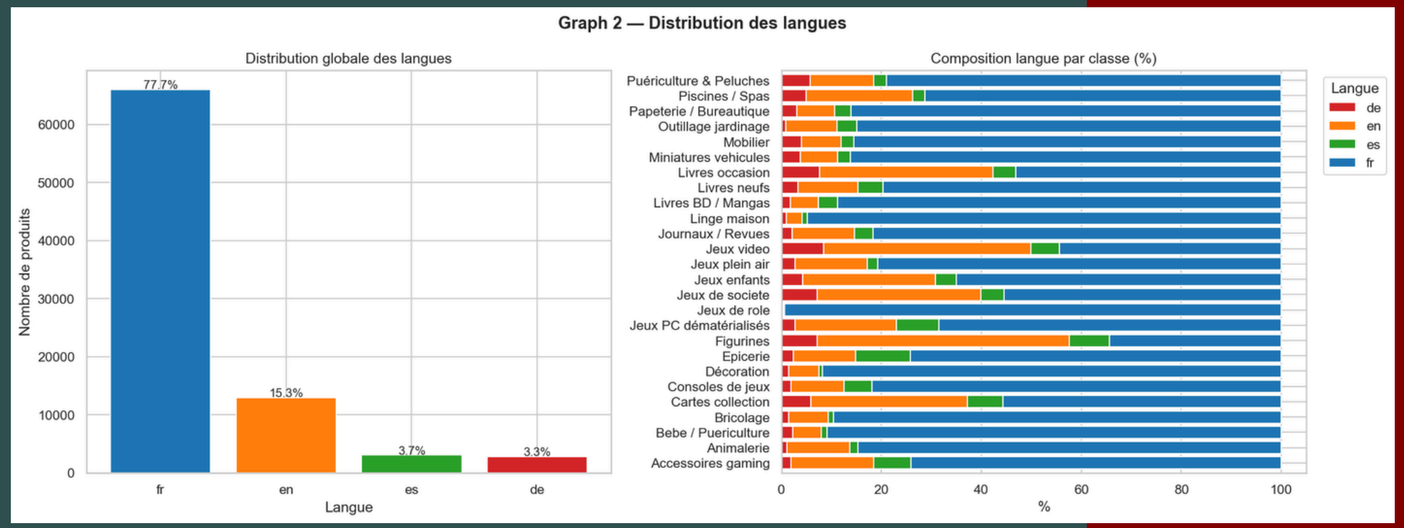
Cette analyse **met en évidence** le déséquilibre des classes, (13:1) confirmant des décisions basées sur des poids de classe équilibrés et une approche stratifiee.

Qualité des Données textuels

Taux de Descriptions Manquantes et Multilinguisme

La qualité des données est essentielle pour le succès d'une classification automatique. Un taux élevé de descriptions manquantes impacte la performance, rendant l'analyse des classes primordiale.

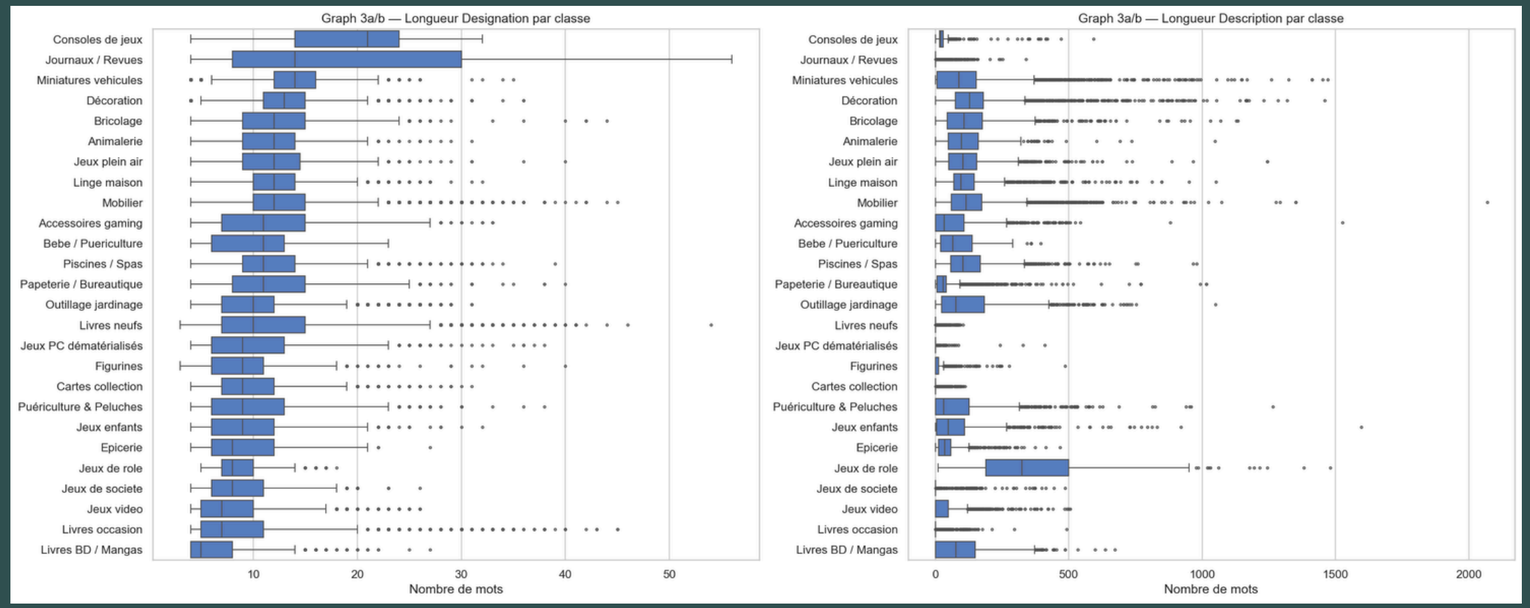




Qualité des Données textuels

Désignations

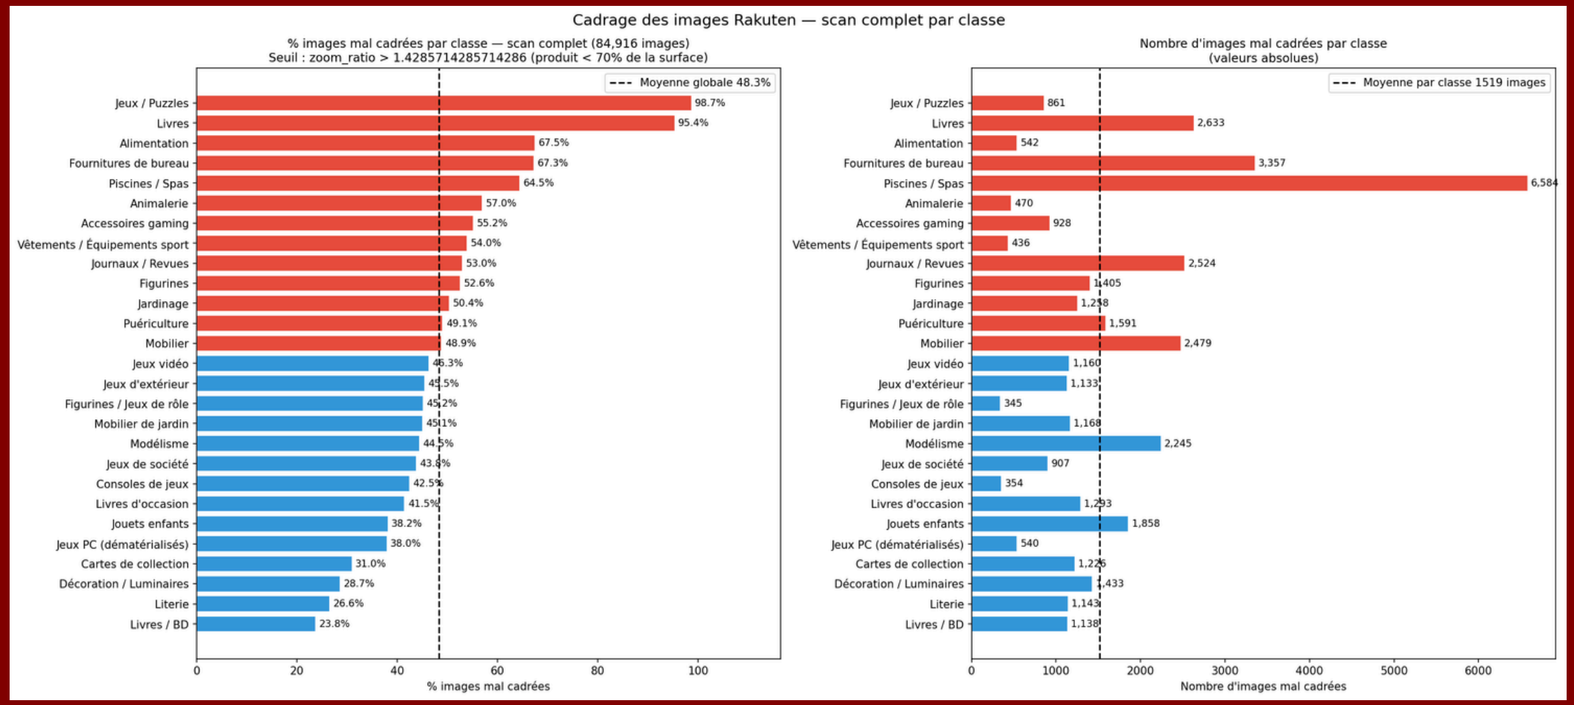
- Désignations courtes : 12 mots en moyenne (majorité < 20 mots)
- Descriptions très variables : 79 mots en moyenne, jusqu'à 2 000 mots
- Forte différence selon les classes produits
- Test de Kruskal–Wallis significatif : p < 0,001
- Variables intégrées au modèle : len_desig, len_desc, len_combined

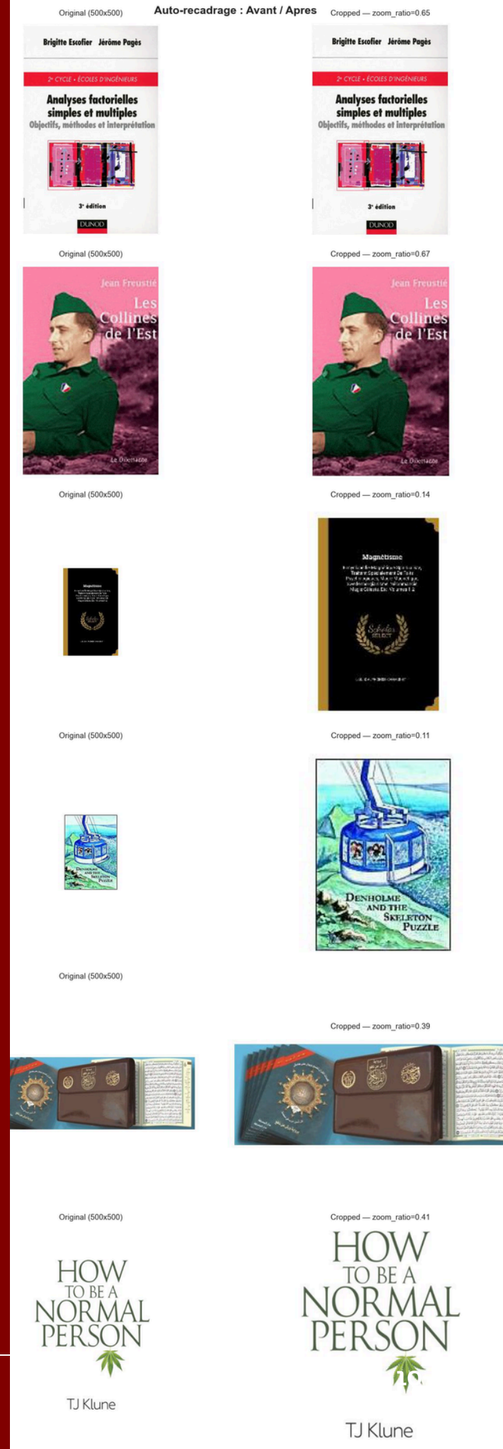


Qualité des Images

Pourcentage d'Images Mal Cadrees

Une analyse approfondie révèle que **48,3 %** des images sont mal cadrées, nécessitant des solutions telles que l'auto-crop pour améliorer la qualité des données visuelles.





Pipeline de Préprocessing Résumé

FEATURE	TYPE	SOURCE	PIPELINE	DESCRIPTION
TEXTE				
`text_combined_raw`	Texte brut	designation + description	SentenceTransformer	Concaténation nettoyée HTML uniquement — préserve le contexte syntaxique pour les Transformers
`text_combined`	Texte nettoyé	designation + description	TF-IDF (baseline)	Stopwords supprimés, casse normalisée, ponctuation retirée, lemmatisé
NUMÉRIQUES				
`len_desig`	Numérique	designation	Tous	Longueur de la désignation en mots — discriminante par classe (Kruskal-Wallis $p < 0.001$)
`len_desc`	Numérique	description	Tous	Longueur de la description en mots — discriminante par classe (Kruskal-Wallis $p < 0.001$)
`len_combined`	Numérique	designation + description	Tous	Somme des deux longueurs — signal global de richesse textuelle
`zoom_ratio`	Numérique	image	Pipeline image	Proportion de l'image occupée par le produit — lié à la classe (Chi^2 $p < 0.001$). Peut devenir obsolète si auto-crop activé
BINAIRES				
`has_desc`	Binaire	description	Tous	1 = description présente, 0 = absente. 35 % de valeurs manquantes non aléatoires (Chi^2 $p < 0.001$)
CATÉGORIELLES				
`language`	Catégoriel	text_combined_raw	Tous	Langue détectée via py3langid — encodée one-hot (fr / en / de / es / unknown). Lié à la classe (Chi^2 $p < 0.001$)
IMAGE				
`image`	Image	image_name	Pipeline image	Image recadrée via auto_crop(), redimensionnée 224×224, normalisée ImageNet (mean/std)
VARIABLE CIBLE				
`label`	Entier (0–26)	prdtypecode	Tous	Encodage LabelEncoder de prdtypecode — 27 classes,

Pipeline de Préprocessing — Texte

Features

- 6 features construites et validées (p < 0,0001) :
  len_desig, len_desc, len_combined (Kruskal–Wallis)
  has_desc (Chi²)
  langue via py3langid (Chi²)
  zoom_ratio (Chi²)

Tests Statistiques

- Tous les tests statistiques retournent des p-values inférieures à 0,0001, validant l'importance des features.

Versions Texte

- text_combined_raw (Transformers), text_combined lemmatisé (TF-IDF) et text_fr traduit pour CamemBERT (deep-translator)

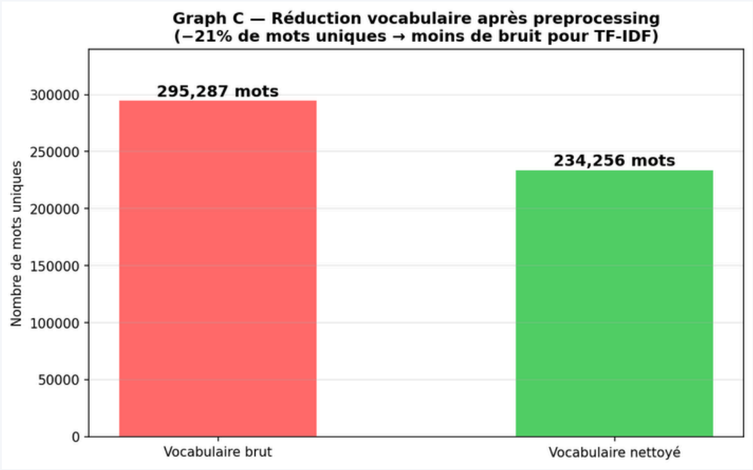
Graph A — Avant / Après nettoyage texte (HTML, stopwords, ponctuation)

Texte BRUT (designation + description)

```
fauteuil chesterfield brenton 100% cuir de buffle - vert empire canapé et fauteuil
chesterfield en cuir antique br enton . coloris : chocolat vert empire ou rouge cherry
disponible en canapé 4 places 3 places 2 places et fauteuil. ses + : - un design mythique
succombez au design mythique du style chesterfield et son capitonnage marqué du dossier
qui font du salon brenton un modèle tendance et intemporel. optez pour la couleur chocolat
et ses reflets châtain ou sortez du commun avec le rouge cherry. vous apprécierez
lattention portée aux détails tels que le capitonnage de la structure de lassis
```

Texte NETTOYÉ (text_combined)

```
fauteuil chesterfield brenton 100 cuir buffle vert empire canapé fauteuil chesterfield
cuir antique enton coloris chocolat vert empire rouge cherry disponible canapé places
places places fauteuil design mythique succombez design mythique chesterfield capitonnage
marqué dossier salon brenton modèle tendance intemporel optez couleur chocolat reflets
châtain sortez commun rouge cherry apprécierez lattention portée détails tels capitonnage
structure lassise coutures daccoudoirs cloutées matériaux premium séduits cuir antique
patiné main apporte salon brenton aspect vieilli très tendance fois esthé
```



Pipeline de Préprocessing — Image

Crop / No-Crop

- 48,3 % des images mal cadrées.

  Fonction auto_crop() : détecte la bounding box sur fond blanc, recadre avec une marge de 2 %.

  Résultat contre-intuitif : autocrop améliore DINOv2 frozen mais dégrade ResNet50 et le stacking.

Analyse Statistique

- Le fond blanc est un signal de contexte implicite, les CNN l'exploitent.

  zoom_ratio validé par Chi^2 : cadrage structurellement lié à la classe ($p < 0{,}0001$).

Pipeline Final

- Images brutes retenues pour le stacking final.

  Autocrop utilisé uniquement pour les expériences DINOv2 frozen.

  Redimensionnement 224×224 + normalisation ImageNet pour toutes les architectures.

Stratégie de Modélisation

Étape 1

Développement du modèle Baseline avec TF-IDF et LightGBM.

Étape 2

Expériences branche unimodal textuels

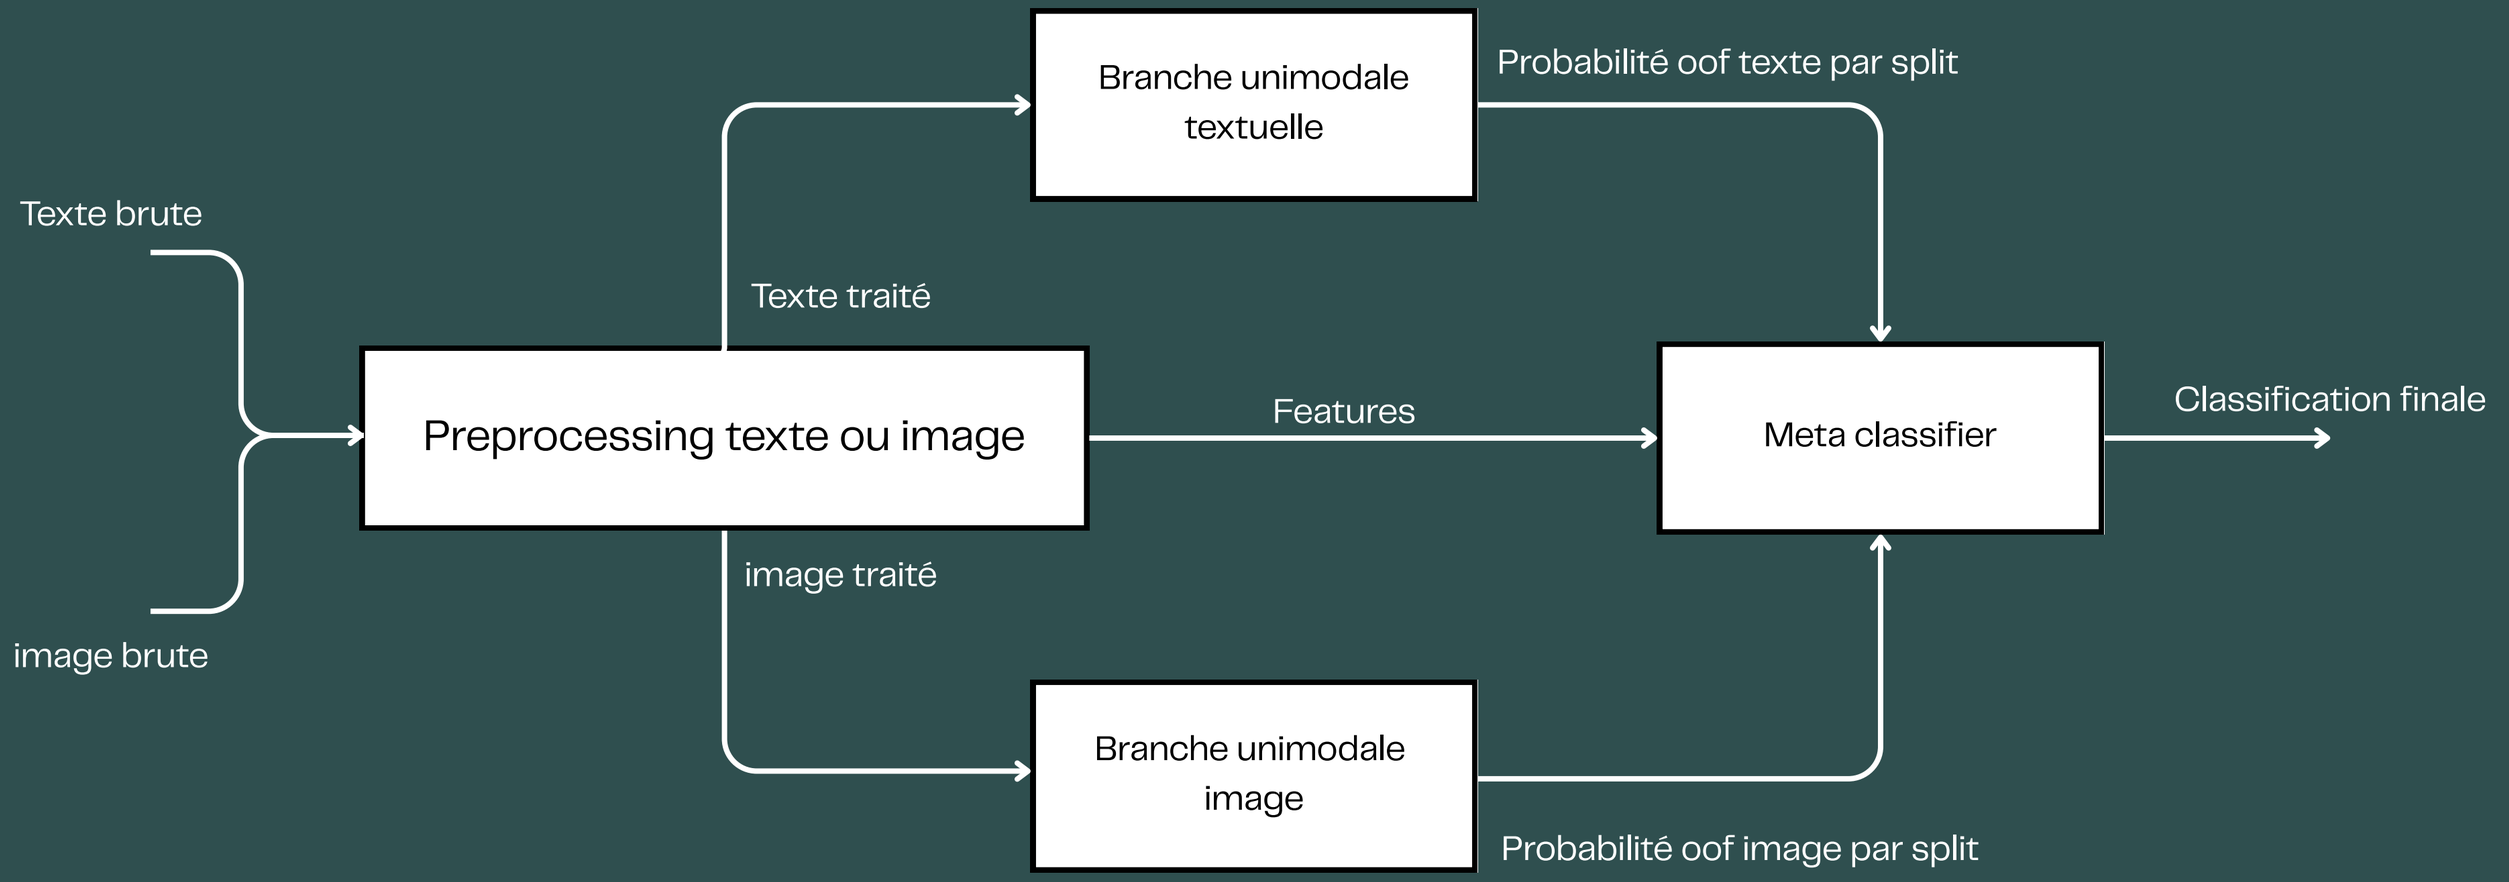
Étape 3

Expériences branche image unimodale

Étape 4

Staking des branches avec un méta classifier

Stratégie de Modélisation



Baseline : TF-IDF + LightGBM

Pourquoi ce choix

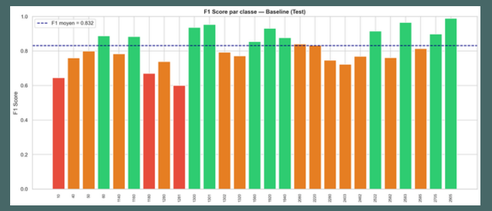
- Chaque classe possède un vocabulaire propre et dense. : TF-IDF capture directement cette spécificité lexicale
- LightGBM gère nativement les matrices sparses de 50 000 features sans densification coûteuse en mémoire. Il supporte class_weight='balanced', indispensable face au déséquilibre 13:1 identifié.

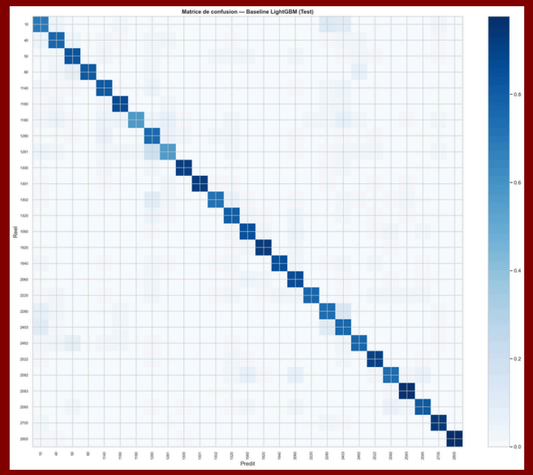
Configuration :

- Features preprocessing (text combined nettoye, indicateur has desc, langue OHE, zoom ratio)
- features image légères (histogramme couleur RGB) afin de tester d'emblée une approche multimodale,

Résultats :

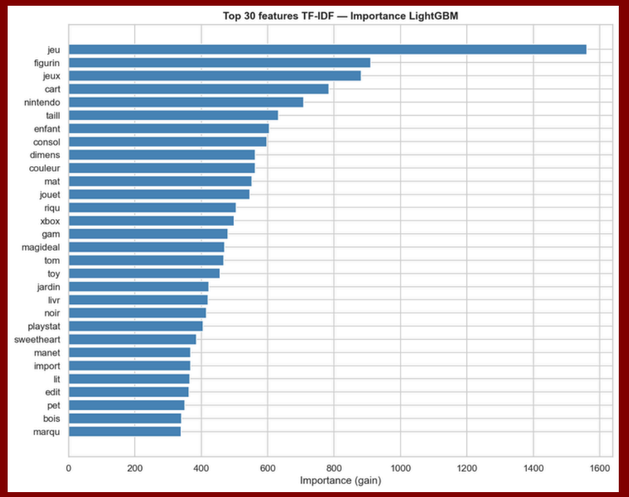
Test : 0,8321





Limites

- **Vocabulaire partagé entre des classes proches**
- **35% de descriptions manquantes**



Expériences branche textes

Expériences

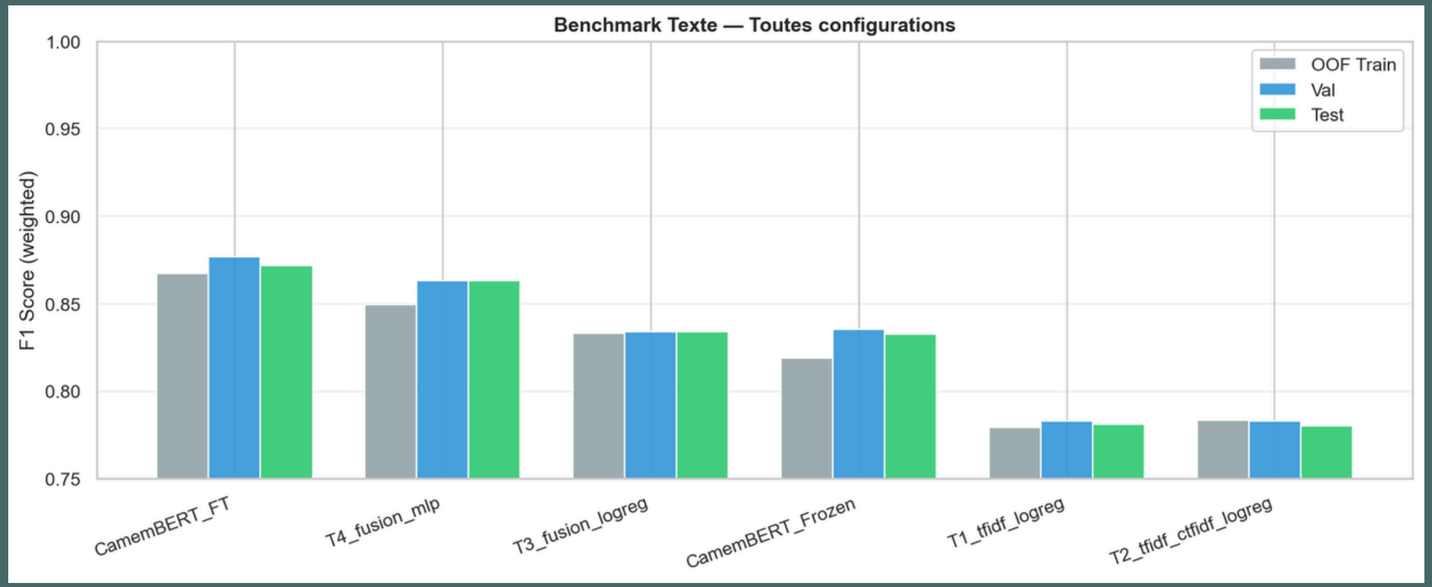
- **T1 : TF-IDF seul + LogReg** : Référence minimale pour mesurer le gain apporté par chaque ajout suivant.
- **T2 : TF-IDF + c-TF-IDF + LogReg** : Ajout de c-TF-IDF : vecteur dense de 27 dimensions directement interprétable comme un score d'affinité par classe.
- **T3 — TF-IDF + c-TF-IDF + e5-large + LogReg :** e5-large peut capturer la similarité sémantique au-delà du token. Livre de poche et roman broché partagent zéro token, mais e5-large les rapproche dans son espace.
- **T4 — TF-IDF + c-TF-IDF + e5-large + MLP :** L'objectif est d'isoler l'apport de la non-linéarité.
- **T5 — CamemBERT gelé + MLP :** extraire le vecteur du token [CLS] et entraîner un MLP dessus.
- **T6 — CamemBERT fine-tuning :** Le fine-tuning permet aux couches profondes de s'adapter au vocabulaire e-commerce Rakuten. Nécessite une traduction préalable des textes non-français, car CamemBERT est mono-langue.

Modèle	MTEB Classification (avg)	Multilingue	Dim.	Retenu
multilingual-e5-large	**64,4**	Oui (100 langues)	1024	✓
paraphrase-multilingual-mpnet-base-v2	59,8	Oui (50 langues)	768	–
sentence-transformers/LaBSE	61,2	Oui (109 langues)	768	–
camembert-base	~58 (FR only)	Non	768	–

ID	Features	Classifieur	F1 OOF	F1 Val	F1 Test
T1	TF-IDF seul	LogReg	0,7792	0,7829	0,7814
T2	TF-IDF + c-TF-IDF	LogReg	0,7833	0,7828	0,7801
T3	TF-IDF + c-TF-IDF + e5-large	LogReg	0,8329	0,8341	0,8341
T4	**TF-IDF + c-TF-IDF + e5-large**	**MLP**	**0,8497**	**0,8632**	**0,8632**
T6	**CamemBERT gelé**	**MLP**	**0,8188**	**0,8353**	**0,8327**
T5	**CamemBERT fine-tuning**	**–**	**0,8672**	**0,8769**	**0,8717**

Expériences textes

Pourquoi CamemBERT est le plus performant ?



Expériences images

ID	Modèle	Approche	F1 OOF	F1 Val	F1 Test
I1	DINOv2-base	Frozen + MLP (no-crop)	0,6901	0,7092	0,7051
I3	DINOv2-base	Frozen + MLP (auto-crop)	0,6942	0,7131	0,7073
ResNet50-FT	ResNet50	Fine-tuning progressif (3 phases)	—	—	0,6853
I2	CLIP ViT-B/32	Frozen + MLP	0,743	0,7577	**0,7486**

Le plafond de la modalité image est d'environ 0,75, indépendamment de l'architecture.

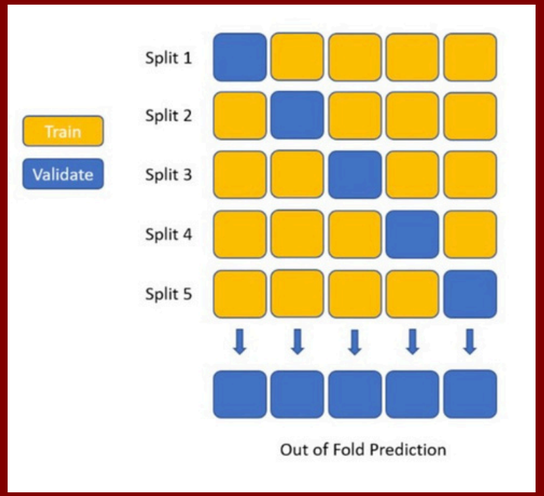
La cause est structurelle : fond blanc uniforme, classes visuellement isomorphes comme livre, manga, magazine et cahier. L'image seule ne peut pas distinguer ces catégories.

Probabilité oof

Probleme : Data Leakage

Si on entraîne CamemBERT sur tout le train, puis qu'on lui demande de prédire des probabilités sur ce même train pour alimenter le MetaMLP, il va produire des probabilités quasi-parfaites sur les exemples qu'il a mémorisés. Le MetaMLP va apprendre à exploiter ce surapprentissage plutôt que le signal généralisable.

Probabilités Out-of-Fold



Stacking Multimodal Meta-modèle

Idée clé :
Le modèle apprend surtout quand faire confiance au texte ou à l'image, via les signaux d'incertitude.

Méta-classifieur basé sur 71 features :

- 54 features : probabilités OOF CamemBERT + CLIP (27 classes chacun)
- 7 features : signaux de confiance (entropie, marge top1–top2, confiance max, accord texte/image)
- 10 features : preprocessing (longueurs, langue, has_desc, zoom_ratio)

Expériences Meta-modèle

Exp	Description	Modeles base	Meta	Feat.	F1 Val	F1 Test	Δ vs E0
E0	Reference NB2 (baseline)	TF-IDF + LightGBM	—	50 522	0,8262	0,8321	—
E1	Texte seul (27 probas)	T4 (TF-IDF+e5+MLP)	LogReg	27	0,8646	0,8642	0,032
E2	Image seule (27 probas)	I2 (CLIP frozen)	LogReg	27	0,7534	0,7462	−0,086
E3	Texte + Image (54 probas)	T4 + I2	LogReg	54	0,8815	0,8825	0,05
E4	+ Meta-scalaires	T4 + I2	LogReg	61	0,8828	0,8823	0,05
E5	+ Meta-scalaires	T4 + I2	LightGBM	61	0,8756	0,8785	0,046
E6	+ Meta-scalaires	T4 + I2	MLP	61	0,8845	0,8845	0,052
E7	+ Preprocessing	T4 + I2	MLP	71	0,888	0,8879	0,056
E8	E7 + image croppee	T4 + I2 (crop)	MLP	71	0,885	0,8849	0,053
E10	**CamemBERT + CLIP nocrop + meta**	**T5_cam + I2**	**MLP**	**61**	**0,8988**	**0,8963**	**0,064**
E11	**CamemBERT + DINOv2 crop + meta**	**T5_cam + I3**	**MLP**	**61**	**0,8947**	**0,8948**	**0,063**

Améliorations incrémentales des performances de classification au cours des différentes étapes de modélisation

Les résultats montrent des **gains significatifs** de performance entre chaque itération, culminant avec le modèle E10 à F1 = 0.8963

Résultats Finaux

Notre modèle E10 atteint un weighted F1-score de 0,8963. Le vainqueur du challenge SIGIR eCom 2020 est à 0,9194, un écart résiduel de 2,31 points.

0.8963

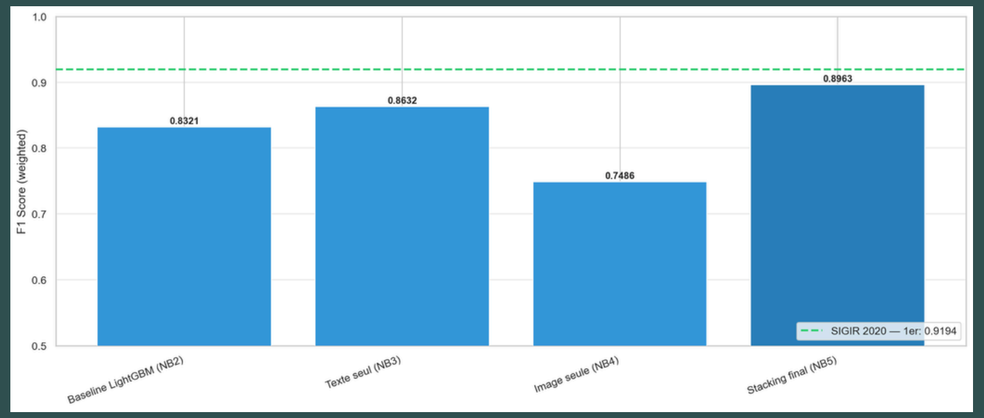
F1 score obtenu

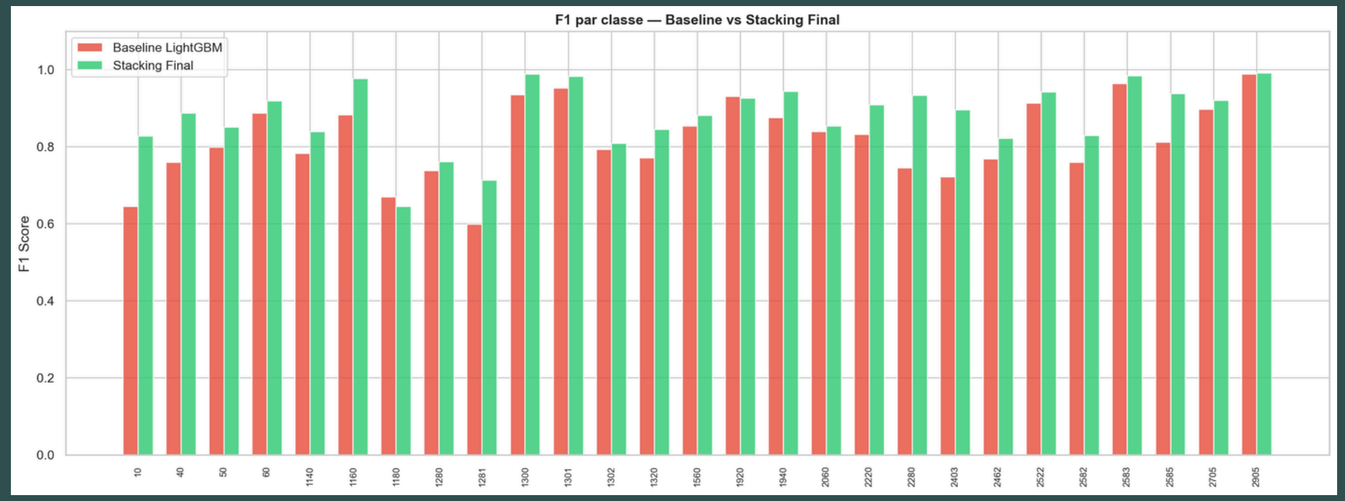
Ce score dépasse significativement notre baseline

33%

Réduction du taux d'erreur

Nous avons obtenu une réduction de 33 % des erreurs de classification.



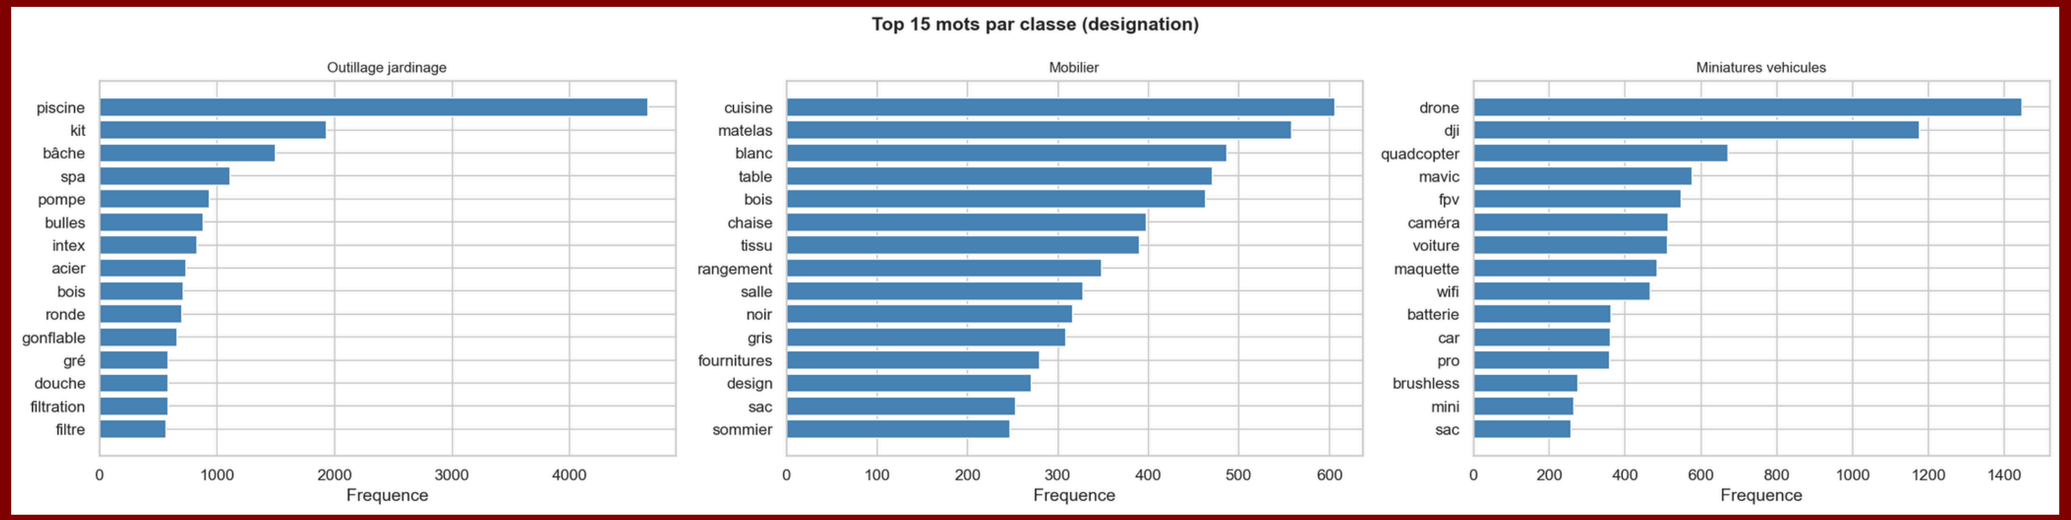


Interprétabilité

Analyse des Méthodes et Résultats

Mots Discriminants

Les mots discriminants par classe ont été identifiés à l'aide de modèles surrogates, révélant des tokens significatifs qui influencent les classifications et facilitent l'interprétation des résultats.



Interprétabilité

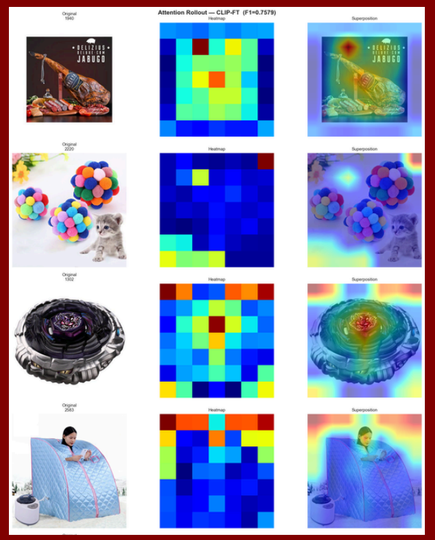
Analyse des Méthodes et Résultats

GradCAM/Attention et SHAP

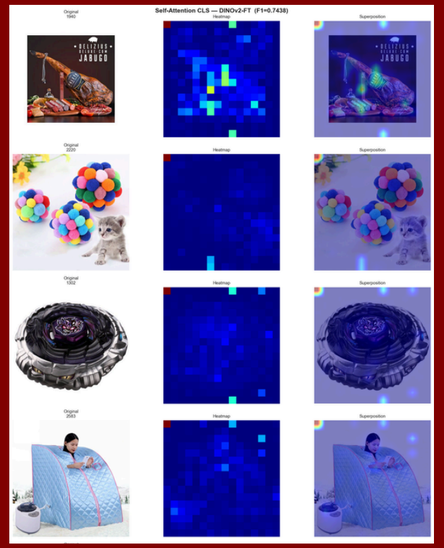
Les visualisations de GradCAM (Resnet50) et de l'attention (CLIP / DinoV2) montrent l'importance des éléments visuels, permettant une meilleure compréhension de l'impact des caractéristiques sur les décisions de classification.

Pour le méta-classifieur. L'entropie de CamemBERT est de très loin la feature la plus importante. Quand CamemBERT hésite, le méta-modèle bascule vers l'image.

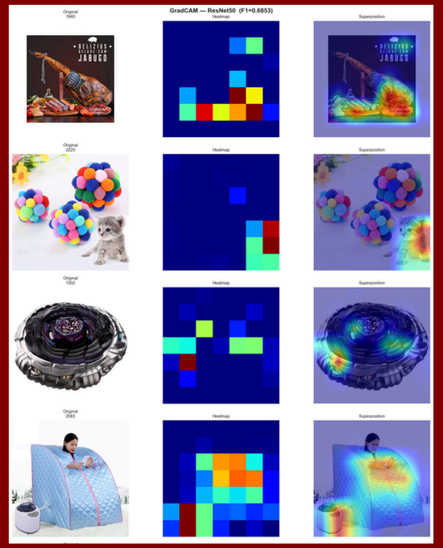
Clip



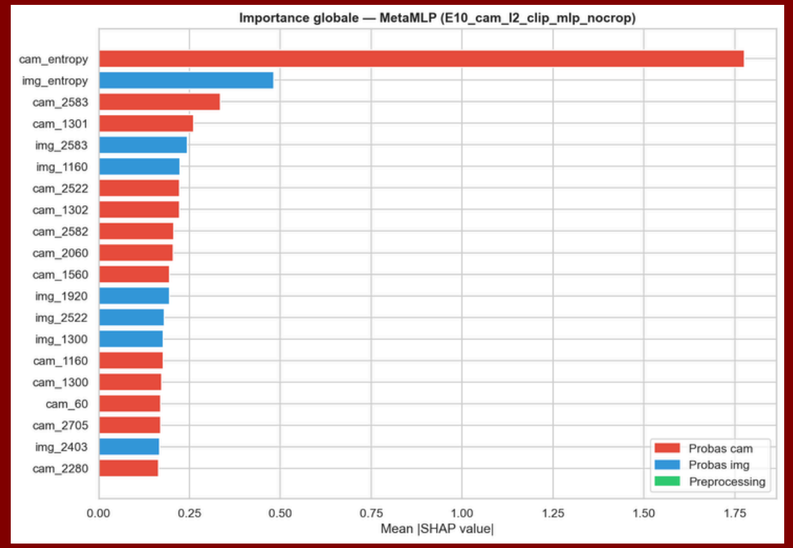
DINOv2

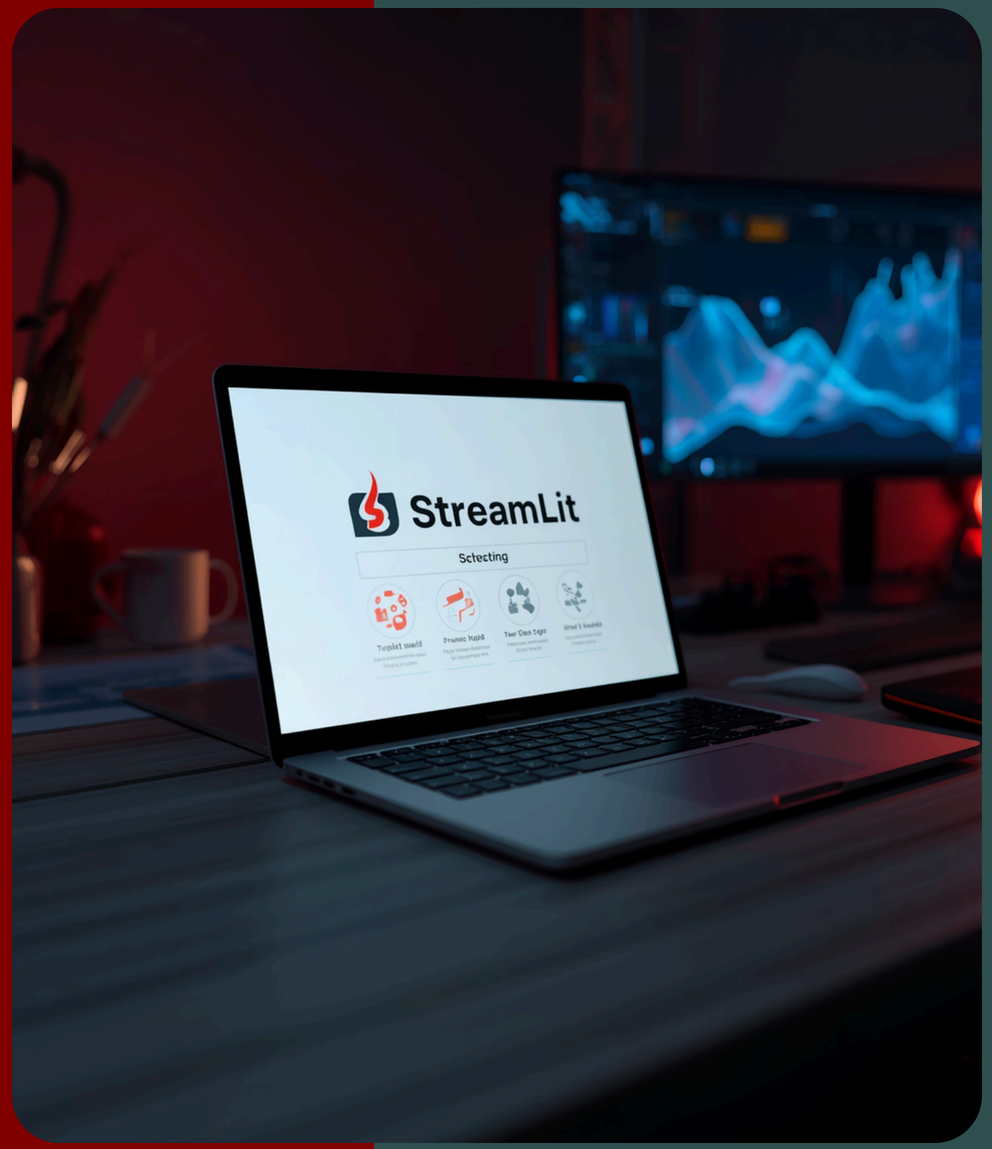


ResNet50



Shap sur le MétaMLP





Démo Streamlit en direct

Visualisation du pipeline en temps réel

Expérimentez les capacités dynamiques de notre pipeline de classification en temps réel, avec des entrées simples (désignation produit et images), permettant d'afficher immédiatement les prédictions et les scores de confiance.

Implications Métier pour Rakuten

01

AUTOMATISATION

Amélioration de l'efficacité via la catalogisation automatique des produits.

02

FIABILITÉ

Seuils de confiance optimisent le flux de validation humaine.

03

QUALITÉ

F1 supérieur à 0,89 assure une qualité élevée des données.

04

MAINTENANCE DU PIPELINE

Si les fournisseurs changent leurs pratiques (fond coloré, recadrage), l'autocrop et les modèles image peuvent se dégrader. Monitoring du F1 par classe + ré-entraînement ciblé recommandés.

Bilan & Perspectives

3 ENSEIGNEMENTS CLES

- Le OOF est indispensable pour éviter toute fuite en stacking
- Un modèle mono-langue fine-tuné peut surpasser un multilingue sur corpus dominé
- L'entropie est un meilleur signal d'incertitude que les probabilités brutes

PERSPECTIVES

- Fine-tuning CLIP end-to-end
- Test-Time Augmentation
- Distillation vers un modèle unique plus léger et rapide

REPRODUCTIBILITÉ

- Pipeline entièrement reproductible via 5 notebooks documentés
- Code : DataScientest-Studio/nov25_alt1_mle_rakuten

Questions?

FORMATION

Data Scientist — Liora — Mai 2026

CHALLENGE

SIGIR eCom 2020 — SOTA : 0,9194

GITHUB

DataScientest-Studio/nov25_alt1_mle_rakuten

